Actividad 5 - Regresión Logística

A00831314- Sofia Reyes

2023-10-20

Librerías

```
library (ISLR)
library(tidyverse)
## -- Attaching core tidyverse packages ----- tidyverse 2.0.0 --
## v dplyr
              1.1.3
                         v readr
                                      2.1.4
## v forcats
               1.0.0
                         v stringr
                                      1.5.0
## v ggplot2
               3.4.3
                         v tibble
                                      3.2.1
## v lubridate 1.9.3
                                      1.3.0
                         v tidyr
## v purrr
               1.0.2
## -- Conflicts -----
                                          -----cidyverse_conflicts() --
## x dplyr::filter() masks stats::filter()
                    masks stats::lag()
## x dplyr::lag()
## i Use the conflicted package (<a href="http://conflicted.r-lib.org/">http://conflicted.r-lib.org/</a>) to force all conflicts to become error
library(vcd)
## Loading required package: grid
## Attaching package: 'vcd'
## The following object is masked from 'package: ISLR':
##
##
       Hitters
```

Análisis de datos

Estadística descriptiva

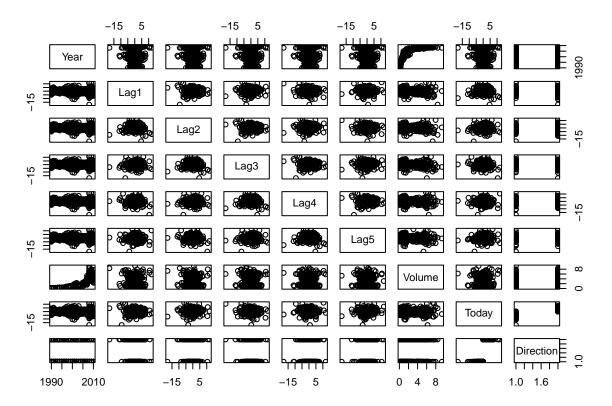
```
head(Weekly)
        Lag1
             Lag2
                  Lag3
                        Lag4
                            Lag5
                                   Volume Today Direction
## 1 1990 0.816 1.572 -3.936 -0.229 -3.484 0.1549760 -0.270
                                                Down
Down
## 3 1990 -2.576 -0.270  0.816  1.572 -3.936  0.1598375  3.514
                                                  Uр
## 4 1990 3.514 -2.576 -0.270 0.816 1.572 0.1616300 0.712
                                                  Uр
Uр
## 6 1990 1.178 0.712 3.514 -2.576 -0.270 0.1544440 -1.372
                                                Down
glimpse(Weekly)
```

Rows: 1,089

```
## Columns: 9
## $ Year
              <dbl> 1990, 1990, 1990, 1990, 1990, 1990, 1990, 1990, 1990, 1990, ~
## $ Lag1
              <dbl> 0.816, -0.270, -2.576, 3.514, 0.712, 1.178, -1.372, 0.807, 0~
              <dbl> 1.572, 0.816, -0.270, -2.576, 3.514, 0.712, 1.178, -1.372, 0~
## $ Lag2
## $ Lag3
              <dbl> -3.936, 1.572, 0.816, -0.270, -2.576, 3.514, 0.712, 1.178, -~
## $ Lag4
              <dbl> -0.229, -3.936, 1.572, 0.816, -0.270, -2.576, 3.514, 0.712, ~
## $ Lag5
              <dbl> -3.484, -0.229, -3.936, 1.572, 0.816, -0.270, -2.576, 3.514,~
## $ Volume
              <dbl> 0.1549760, 0.1485740, 0.1598375, 0.1616300, 0.1537280, 0.154~
## $ Today
              <dbl> -0.270, -2.576, 3.514, 0.712, 1.178, -1.372, 0.807, 0.041, 1~
## $ Direction <fct> Down, Down, Up, Up, Up, Down, Up, Up, Up, Down, Down, Up, Up~
summary(Weekly)
##
        Year
                       Lag1
                                          Lag2
                                                             Lag3
##
   Min.
          :1990
                  Min. :-18.1950
                                     Min. :-18.1950
                                                        Min. :-18.1950
##
   1st Qu.:1995
                  1st Qu.: -1.1540
                                     1st Qu.: -1.1540
                                                        1st Qu.: -1.1580
   Median:2000
                  Median : 0.2410
                                     Median: 0.2410
                                                        Median: 0.2410
##
   Mean
          :2000
                  Mean
                         : 0.1506
                                     Mean
                                           : 0.1511
                                                        Mean
                                                              : 0.1472
   3rd Qu.:2005
                  3rd Qu.: 1.4050
                                     3rd Qu.: 1.4090
                                                        3rd Qu.: 1.4090
##
##
   Max.
          :2010
                        : 12.0260
                                           : 12.0260
                                                        Max.
                                                              : 12.0260
                  Max.
                                     Max.
##
        Lag4
                           Lag5
                                             Volume
                                                               Today
   Min. :-18.1950
                                                :0.08747
##
                      Min.
                             :-18.1950
                                         Min.
                                                           Min.
                                                                  :-18.1950
##
   1st Qu.: -1.1580
                      1st Qu.: -1.1660
                                         1st Qu.:0.33202
                                                           1st Qu.: -1.1540
##
   Median : 0.2380
                      Median : 0.2340
                                         Median :1.00268
                                                           Median: 0.2410
   Mean : 0.1458
                      Mean : 0.1399
                                         Mean
                                               :1.57462
                                                           Mean : 0.1499
   3rd Qu.: 1.4090
                      3rd Qu.: 1.4050
                                                           3rd Qu.: 1.4050
##
                                         3rd Qu.:2.05373
##
   Max.
          : 12.0260
                      Max. : 12.0260
                                         Max.
                                                :9.32821
                                                           Max. : 12.0260
##
   Direction
   Down: 484
##
##
   Up :605
##
##
##
```

pairs(Weekly)

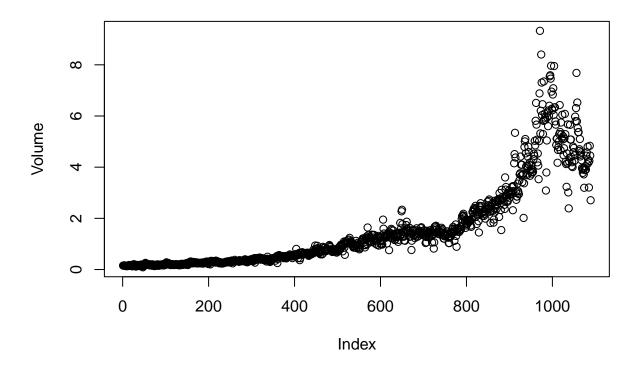
##



Coeficiente de correlación

```
cor(Weekly[,-9])
```

```
##
                       Lag1
                                Lag2
                                         Lag3
        1.00000000 -0.032289274 -0.03339001 -0.03000649 -0.031127923
## Year
       -0.03228927 1.000000000 -0.07485305 0.05863568 -0.071273876
## Lag1
       -0.03339001 -0.074853051 1.00000000 -0.07572091 0.058381535
## Lag2
       ## Lag3
       ## Lag4
## Lag5
       ## Volume 0.84194162 -0.064951313 -0.08551314 -0.06928771 -0.061074617
       -0.03245989 -0.075031842 0.05916672 -0.07124364 -0.007825873
## Today
##
                     Volume
              Lag5
                                Today
## Year
       -0.008183096 -0.06495131 -0.075031842
## Lag1
## Lag2
       -0.072499482 -0.08551314 0.059166717
       0.060657175 -0.06928771 -0.071243639
## Lag3
## Lag4
       -0.075675027 -0.06107462 -0.007825873
        1.000000000 -0.05851741 0.011012698
## Lag5
## Volume -0.058517414 1.00000000 -0.033077783
        0.011012698 -0.03307778 1.000000000
## Today
attach(Weekly)
plot(Volume)
```



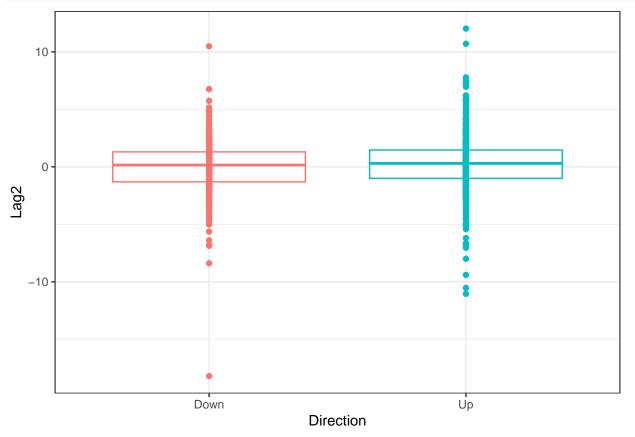
Modelo logístico

```
modelo.log.m <- glm(Direction ~ . - Today, family = binomial, data = Weekly)</pre>
summary(modelo.log.m)
##
## glm(formula = Direction ~ . - Today, family = binomial, data = Weekly)
##
## Deviance Residuals:
##
       Min
                 10
                      Median
                                    3Q
                                            Max
## -1.7071 -1.2578
                      0.9941
                               1.0873
                                         1.4665
##
## Coefficients:
                Estimate Std. Error z value Pr(>|z|)
                                     0.455
                                               0.6494
## (Intercept) 17.225822 37.890522
## Year
               -0.008500
                           0.018991 -0.448
                                               0.6545
## Lag1
               -0.040688
                           0.026447
                                     -1.538
                                               0.1239
## Lag2
                0.059449
                           0.026970
                                      2.204
                                               0.0275 *
## Lag3
               -0.015478
                           0.026703
                                     -0.580
                                               0.5622
               -0.027316
                           0.026485
                                     -1.031
                                               0.3024
## Lag4
                                     -0.531
               -0.014022
                           0.026409
                                               0.5955
## Lag5
                0.003256
                                     0.047
## Volume
                           0.068836
                                               0.9623
## Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
## (Dispersion parameter for binomial family taken to be 1)
##
##
       Null deviance: 1496.2 on 1088 degrees of freedom
## Residual deviance: 1486.2 on 1081 degrees of freedom
## AIC: 1502.2
```

```
##
## Number of Fisher Scoring iterations: 4
confint(object = modelo.log.m, level = 0.95)
## Waiting for profiling to be done...
                       2.5 %
                                  97.5 %
## (Intercept) -56.985558236 91.66680901
## Year
                -0.045809580 0.02869546
## Lag1
                -0.092972584 0.01093101
## Lag2
                0.007001418 0.11291264
## Lag3
                -0.068140141 0.03671410
                -0.079519582 0.02453326
## Lag4
## Lag5
                -0.066090145
                             0.03762099
## Volume
                -0.131576309
                             0.13884038
```

Con la información mostrada de este primer modelo, se puede observar como solamente la variable Lag2 es significante para el modelo al tener un p-valor relativamente bajo. Además, con los coeficientes del modelo B0 = 17.22 y B1 = 0.059, el valor del algoritmo siempre será positivo y aumentará conforme al tiempo, lo que resulta en el crecimiento de los momios.

```
ggplot(data = Weekly, mapping = aes(x = Direction, y = Lag2)) +
geom_boxplot(aes(color = Direction)) +
geom_point(aes(color = Direction)) +
theme_bw() +
theme(legend.position = "null")
```



División entrenamiento y prueba

```
# Training: 1990-2008
datos.entrenamiento <- (Year < 2009)
# Test: 2009-2010
datos.test <- Weekly[!datos.entrenamiento, ]</pre>
```

Formuluación del modelo solo con las variables significativas

```
modelo.log.s <- glm(Direction ~ Lag2, data = Weekly, family = binomial,</pre>
subset = datos.entrenamiento)
summary(modelo.log.s)
##
## Call:
## glm(formula = Direction ~ Lag2, family = binomial, data = Weekly,
      subset = datos.entrenamiento)
## Deviance Residuals:
     Min 1Q Median
                              3Q
                                     Max
## -1.536 -1.264 1.021 1.091
                                   1.368
## Coefficients:
              Estimate Std. Error z value Pr(>|z|)
## (Intercept) 0.20326
                          0.06428 3.162 0.00157 **
## Lag2
               0.05810
                          0.02870 2.024 0.04298 *
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
## (Dispersion parameter for binomial family taken to be 1)
##
      Null deviance: 1354.7 on 984 degrees of freedom
## Residual deviance: 1350.5 on 983 degrees of freedom
## AIC: 1354.5
## Number of Fisher Scoring iterations: 4
```

Representación Gráfica

```
nuevos_puntos <- seq(from = min(Weekly$Lag2), to = max(Weekly$Lag2), by = 0.5)

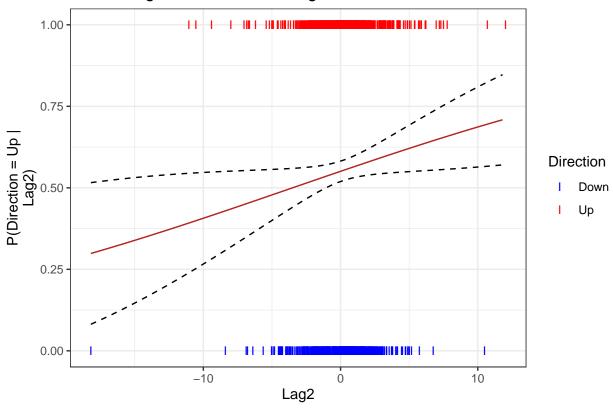
# Predicción de los nuevos puntos según el modelo
predicciones <- predict(modelo.log.s, newdata = data.frame(Lag2 = nuevos_puntos), se.fit = TRUE, type = "response")

# Límites del intervalo de confianza (95%) de las predicciones
CI_inferior <- predicciones$fit - 1.96 * predicciones$se.fit
CI_superior <- predicciones$fit + 1.96 * predicciones$se.fit

# Matriz de datos con los nuevos puntos y sus predicciones
datos_curva <- data.frame(Lag2 = nuevos_puntos, probabilidad = predicciones$fit, CI.inferior = CI_infer
# Codificación 0,1 de la variable respuesta Direction
Weekly$Direction <- ifelse(Weekly$Direction == "Down", yes = 0, no = 1)
```

```
ggplot(Weekly, aes(x = Lag2, y = Direction)) +
geom_point(aes(color = as.factor(Direction)), shape = "I", size = 3) +
geom_line(data = datos_curva, aes(y = probabilidad), color = "firebrick") +
geom_line(data = datos_curva, aes(y = CI.superior), linetype = "dashed") +
geom_line(data = datos_curva, aes(y = CI.inferior), linetype = "dashed") +
labs(title = "Modelo logístico Direction ~ Lag2", y = "P(Direction = Up |
Lag2)", x = "Lag2") +
scale_color_manual(labels = c("Down", "Up"), values = c("blue", "red")) +
guides(color=guide_legend("Direction")) +
theme(plot.title = element_text(hjust = 0.5)) +
theme_bw()
```

Modelo logístico Direction ~ Lag2



Evaluación del modelo

Prueba de Chi Cuadrada

```
anova(modelo.log.s, test ='Chisq')

## Analysis of Deviance Table

##

## Model: binomial, link: logit

##

## Response: Direction

##

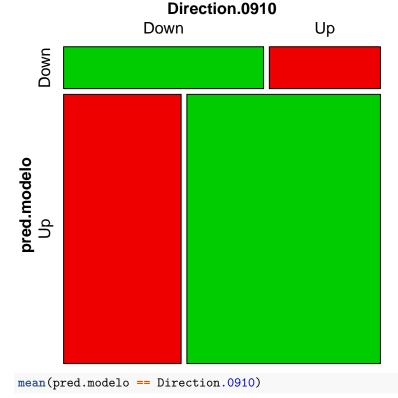
## Terms added sequentially (first to last)

##
```

Al tener un valor p de 0.04, este es menor que alfa y por ende el modelo puede considerarse significativo bajo esta prueba.

Matriz de confusión

```
# Cálculo de la probabilidad predicha por el modelo con los datos de test
prob.modelo <- predict(modelo.log.s, newdata = datos.test, type = "response")
# Vector de elementos "Down"
pred.modelo <- rep("Down", length(prob.modelo))
# Sustitución de "Down" por "Up" si la p > 0.5
pred.modelo[prob.modelo > 0.5] <- "Up"
Direction.0910 = Direction[!datos.entrenamiento]
# Matriz de confusión
matriz.confusion <- table(pred.modelo, Direction.0910)
mosaic(matriz.confusion, shade = T, colorize = T, gp = gpar(fill = matrix(c("green3", "red2", "green3"), 2, 2)))</pre>
```



[1] 0.625

Ecuación del modelo e interpretación

 $e^{0.203+0.0581Lag2}$

Gracias a la matriz de confusión y la ecuación del modelo, se puede observar como la variable Lag2 junto con su coeficiente tienen una relación directa con la variable dependiente, además de ser la única significativa para este modelo. Esto significa que el valor de las acciones 2 semanas atrás puede ayudar a predecir la dirección (up o down) del comportamiento de las acciones.